CS336 Lecture 3 学习讲义

> 副标题：现代大语言模型架构、超参数与稳定训练经验
>
> 适用对象：正在上 CS336 的课程同学
>
> 依据材料：2025 Lecture 3 - architecture.pdf

目录2. 在不偏离讲义内容的前提下，重新组织结构，让它更像一份系统化教材

1. 这节课在讲什么
2. 从标准 Transformer 到现代 LM：哪些东西变了，哪些没变
3. 归一化与残差路径：为什么现代模型几乎都用 pre-norm
4. LayerNorm、RMSNorm 与去 bias：现代块结构的主流选择
5. FFN 与激活函数：为什么 SwiGLU 成了近年的默认答案
6. Serial block 与 parallel block：块内并行到底值不值得
7. 位置编码全景图：从绝对位置到相对位置
8. RoPE：现代 LLM 最常见的位置编码
9. 超参数经验：`d_ff` 、head dim、深宽比例、词表大小
10. 正则化与稳定训练：dropout、weight decay、z-loss、QK norm
11. 注意力推理优化：KV cache、MQA、GQA、滑动窗口注意力
12. 如果今天自己做一个现代 LM，默认怎么选
13. 高频考点与常见误区
14. 附：最小代码实现片段

1. 这节课在讲什么

`lecture2` 主要回答的是：

- 训练一个模型需要哪些底层 primitive
- 怎么算内存
- 怎么算 FLOPs

- 怎么把训练循环跑起来

而 `lecture3` 回答的是另一个非常关键的问题：

> 现代大语言模型在“架构设计”和“训练细节”上，究竟形成了哪些共识？

这节课不是在教你再背一遍标准 Transformer，而是在做更接近研究与工程实践的事情：

- 哪些架构选择几乎已经成为默认答案
- 哪些超参数其实没有那么敏感
- 哪些训练 trick 对稳定性和效率确实重要
- 哪些变体主要是为了推理成本，而不是训练精度

原 slide 的主题可以压缩成一句话：

> 不要只会实现一个“课本 Transformer”，还要知道现代 LLM 通常为什么长成今天这个样子。

2. 从标准 Transformer 到现代 LM：哪些东西变了，哪些没变

讲义首先回顾了“原始 Transformer”与课程作业里“现代简化版”之间的区别。

标准 Transformer 常见设定：

- 位置编码：正弦余弦
- FFN 激活：ReLU
- 归一化：post-norm LayerNorm
- 线性层常带 bias

而课程实现的现代化简版更接近近年大模型习惯：

- pre-norm
- RoPE
- SwiGLU
- 大量线性层和 norm 层不带 bias

What you implemented – simple, modern variant

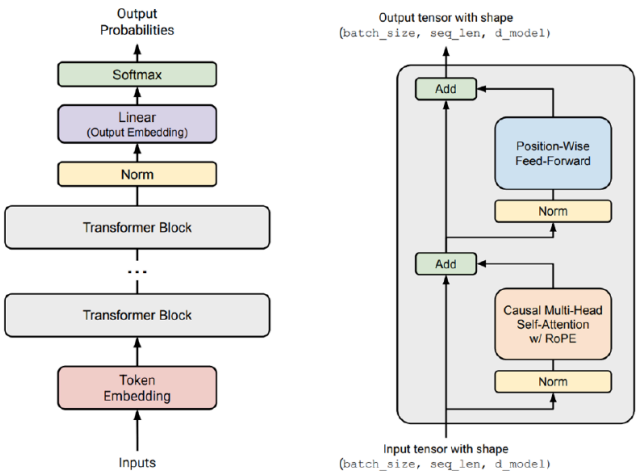

Differences:

- **LayerNorm** is in front of the block
- **Rotary position embeddings (RoPE)**
- FF layers use **SwiGLU**, not ReLU
- Linear layers (and layernorm) have **no bias** (constant) terms

Why did we pick these?
What should you pick?

这张图对应的核心问题其实不是“我们为什么这样实现作业”，而是：

- 这些改动是不是已经构成现代 LLM 的共识
- 如果你今天重新设计一个 dense decoder-only LM，你的默认起点应该是什么

这节课给出的总体判断是：

- 大体骨架仍然是 Transformer
- 但很多局部组件已经朝 “LLaMA-like” 方向收敛
- 真正变化最频繁的地方，通常是 position embedding、FFN 设计、attention 推理优化和稳定性 trick

3. 归一化与残差路径：为什么现代模型几乎都用 pre-norm

3.1 pre-norm vs post-norm 是什么

先回忆一个 Transformer block 的基本形态。假设 block 内有两个子层：

- self-attention
- FFN

那么两种典型写法是：

post-norm

```
x = x + Attention(x)
x = LayerNorm(x)
x = x + FFN(x)
x = LayerNorm(x)
```

pre-norm

```
x = x + Attention(LayerNorm(x))
x = x + FFN(LayerNorm(x))
```

它们最大的差别在于：

- `post-norm` ：归一化发生在残差加法之后
- `pre-norm` ：归一化发生在子层内部输入处，残差主路径尽量保持“干净”

Pre-vs-post norm

The one thing *everyone* agrees on (in 2024)

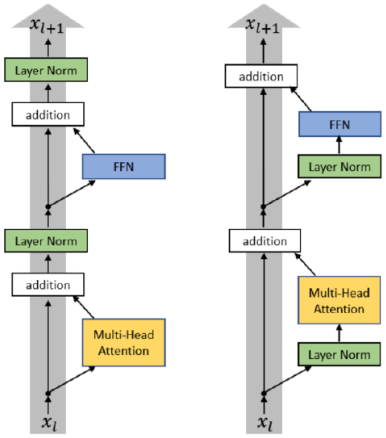

Figure from Xiong 2020

Post-LN Transformer	Pre-LN Transformer
$x_{l,i}^{post,1} = \text{MultiHeadAtt}(x_{l,i}^{post}, [x_{l,1}^{post}, \cdots, x_{l,n}^{post}])$	$x_{l,i}^{pre,1} = \text{LayerNorm}(x_{l,i}^{pre})$
$x_{l,i}^{post,2} = x_{l,i}^{post} + x_{l,i}^{post,1}$	$x_{l,i}^{pre,2} = \text{MultiHeadAtt}(x_{l,i}^{pre,1}, [x_{l,1}^{pre,1}, \cdots, x_{l,n}^{pre,1}])$
$x_{l,i}^{post,3} = \text{LayerNorm}(x_{l,i}^{post,2})$	$x_{l,i}^{pre,3} = x_{l,i}^{pre} + x_{l,i}^{pre,2}$
$x_{l,i}^{post,4} = \text{ReLU}(x_{l,i}^{post,3} W^{1,l} + b^{1,l}) W^{2,l} + b^{2,l}$	$x_{l,i}^{pre,4} = \text{LayerNorm}(x_{l,i}^{pre,3})$
$x_{l,i}^{post,5} = x_{l,i}^{post,3} + x_{l,i}^{post,4}$	$x_{l,i}^{pre,5} = \text{ReLU}(x_{l,i}^{pre,4} W^{1,l} + b^{1,l}) W^{2,l} + b^{2,l}$
$x_{l+1,i}^{post} = \text{LayerNorm}(x_{l,i}^{post,5})$	$x_{l+1,i}^{pre} = x_{l,i}^{pre,5} + x_{l,i}^{pre,3}$
	Final LayerNorm: $x_{Final,i}^{pre} \leftarrow \text{LayerNorm}(x_{L+1,i}^{pre})$

Set up LayerNorm so that it doesn’t affect the main residual signal path (on the left)

Almost all modern LMs use pre-norm (but BERT was post-norm)

(One somewhat funny exception – OPT350M. I don’t know why this is post-norm)

3.2 为什么现代模型几乎都用 pre-norm

原讲义态度非常明确：

> 这几乎是 2024 年大家唯一普遍同意的事情。

背后的直觉是：

- 残差连接的价值在于提供稳定的信息与梯度通路
- 如果 LayerNorm 直接卡在主残差路径上，会改变这条通路的“直达性”
- pre-norm 把 norm 放到分支里，能更好保留残差路径的好处

slide 中给出的几类解释包括：

- gradient attenuation
- gradient spikes
- 更稳定的优化
- 更容易使用较大的学习率
- 减少对 warmup 的依赖

3.3 一个更工程化的理解

把这个问题说得更工程一点：

- 深层网络训练最怕梯度传播不稳
- 残差本来是为了解决深网络优化难题
- 所以最好不要让归一化过度干扰主残差流

这也是为什么现代 decoder-only LLM 基本默认：

- pre-norm

即便某些历史模型用了 post-norm，也更像旧时代遗留，而不是现代默认。

3.4 “double norm” 是什么

slide 还提到一个新趋势：所谓的 “double norm”。

它的思路不是回到传统 post-norm，而是：

- block 内部仍然保持 pre-norm
- 但在残差流之外，再加一个额外的归一化位置

你可以把它理解成：

- 不破坏 pre-norm 的核心优势
- 同时尝试进一步稳定输出分布

这类做法在一些较新的模型中出现，但还没有像 pre-norm 那样形成绝对共识。

4. LayerNorm、RMSNorm 与去 bias：现代块结构的主流选择

4.1 LayerNorm 在做什么

传统 LayerNorm 对每个 token 的 hidden 向量做归一化，通常会减均值、除标准差，再乘可学习参数：

$$\mathrm{LayerNorm}(x) = \gamma \cdot \frac{x - \mu}{\sqrt{\sigma^2 + \epsilon}} + \beta$$

这里：

- γ 是 scale
- β 是 bias
- 会显式减去均值

4.2 RMSNorm 在做什么

RMSNorm 更简单，它不减均值，只按均方根做缩放：

$$\mathrm{RMSNorm}(x) = \gamma \cdot \frac{x}{\sqrt{\frac{1}{d}\sum_i x_i^2 + \epsilon}}$$

也就是说：

- 不做 mean-centering
- 通常没有 bias
- 参数更少，访存更轻

LayerNorm vs RMSNorm

Original transformer: **LayerNorm** – normalizes the mean and variance across d_{model}

$$y = \frac{x - \mathrm{E}[x]}{\sqrt{\mathrm{Var}[x] + \epsilon}} * \gamma + \beta$$

Notable models:

GPT3/2/1, OPT, GPT-J, BLOOM

Many modern LMs: **RMSNorm** – does not subtract mean or add a bias term

$$y = \frac{x}{\sqrt{||x||_2^2 + \varepsilon}} * \gamma$$

Notable models:

LLaMA-family, PaLM, Chinchilla, T5

4.3 为什么很多现代模型偏向 RMSNorm

讲义里给出的主因很朴素：

- 更快
- 参数更少
- 运行时数据搬运更少
- 实际效果通常不差

一个重要提醒是：

> FLOPs 不是 runtime。

即使 RMSNorm 相比 LayerNorm 少掉的浮点操作看起来不大，它依然可能带来真实 wall-clock 改善，因为现代 GPU 系统里很多瓶颈来自：

- memory access
- kernel launch
- 数据搬运

而不是单纯的算术数量。

4.4 为什么“少一点点操作”也可能有意义

在 lecture2 里我们学过：

- 大头 FLOPs 确实来自 matmul

但这并不意味着小组件的优化无意义。因为：

- matmul 主导 FLOPs
- norm、bias、reshape、memory movement 常常影响实际吞吐和 kernel 效率

也就是说：

- “不占 FLOPs 大头” 不等于 “不影响速度”

这是现代训练工程里一个非常重要的思维转变。

4.5 去掉 bias 为什么也成了主流

slide 还提到一个趋势：

> 现代 Transformer 往往连 linear 层和 norm 层里的 bias 都省掉。

原因主要有两个：

- 节省参数和访存
- 有时对优化稳定性更友好

对超大模型来说，这种简化积累起来是有意义的：

- 少一个 bias 向量不算什么
- 但每层、每模块、每次前向后向都少一点，整体就有价值

4.6 一个最小 RMSNorm 实现

```python
import torch
from torch import nn


class RMSNorm(nn.Module):
    def __init__(self, dim: int, eps: float = 1e-6):
        super().__init__()
        self.eps = eps
        self.weight = nn.Parameter(torch.ones(dim))

    def forward(self, x: torch.Tensor) -> torch.Tensor:
        rms = x.pow(2).mean(dim=-1, keepdim=True).add(self.eps).rsqrt()
        return x * rms * self.weight
```

这个实现正好对应 RMSNorm 的本质：

- 不减均值
- 只按均方根缩放
- 只有 scale，没有 bias

4.7 这一节要带走的结论

- pre-norm 基本已成现代主流
- RMSNorm 是现代 dense LLM 的常见默认选择
- 去掉 bias 是常见配套操作
- 不要只盯 FLOPs，要考虑数据移动和实际吞吐

5. FFN 与激活函数：为什么 SwiGLU 成了近年的默认答案

5.1 FFN 不只是“两层 MLP”

标准 Transformer 的前馈层通常写成：

$$\mathrm{FFN}(x) = \phi(xW_1)W_2$$

其中 φ 是激活函数。

最早常见的是：

- ReLU

后来很多 GPT 系列用了：

- GeLU

而近几年大量模型转向：

- GeGLU
- SwiGLU

5.2 为什么会有这么多激活函数

因为 FFN 是 Transformer 中非常重要的非线性来源。不同激活的差别体现在：

- 表达能力
- 优化稳定性
- 参数利用效率
- 与大规模训练的兼容性

5.3 ReLU 和 GeLU

最基础版本：

```
import torch
import torch.nn.functional as F

x = torch.randn(4, 8)

relu_y = F.relu(x)
gelu_y = F.gelu(x)
```

直觉上：

- `ReLU`：简单、硬阈值、便宜
- `GeLU`：更平滑，GPT 系模型长期使用

5.4 什么是 GLU 家族

GLU 的核心思想不是换一个单独激活，而是：

> 给 FFN 加一个门控分支，让一个分支去调制另一个分支。

slide 中先从 ReGLU 讲起：

$$\mathrm{FF}_{\mathrm{ReGLU}}(x) = (\max(0, xW_1) \otimes xV)W_2$$

这里的关键变化是：

- 不再只是 `activation(xW1)`
- 而是 `activation(xW1) * gate(xV)`

也就是典型的 gating 思路。

5.5 为什么 gating 有可能更强

门控机制本质上提供了更细粒度的特征选择能力：

- 某些通道可以被增强
- 某些通道可以被压低
- 非线性不仅来自激活，也来自乘法式调制

这类结构在大模型里往往能带来：

- 更好的参数利用
- 稳定但不算特别夸张的性能提升

5.6 SwiGLU 与 GeGLU 为什么流行

讲义列出的现代模型里，大量后 2023 模型都偏向：

- SwiGLU
- GeGLU

其中 SwiGLU 常写成：

$$\mathrm{SwiGLU}(x) = (\mathrm{Swish}(xW_1) \otimes xV)W_2$$

而 `Swish(z) = z \cdot \sigma(z)` 。

Gated variants of standard FF layers

GeGLU

$$\mathrm{FFN}_{\mathrm{GEGLU}}(x, W, V, W_2) = (\mathrm{GELU}(xW) \otimes xV)W_2$$

Notable models:

T5 v1.1, mT5, LaMDA, Phi3, Gemma 2, Gemma 3

SwiGLU (swish is $x * \mathrm{sigmoid}(x)$)

$$\mathrm{FFN}_{\mathrm{SwiGLU}}(x, W, V, W_2) = (\mathrm{Swish}_1(xW) \otimes xV)W_2$$

Notable models:

LLaMa 1/2/3, PaLM, Mistral, OlMo, *most models post 2023*

Note: Gated models use smaller dimensions for the d_{ff} by 2/3

5.7 为什么 gated FFN 经常把 `d_ff` 缩小到约 `8/3 d_model`

这是很多同学第一次看到会疑惑的地方。

标准 FFN 常见配置是：

$$d_{ff} = 4d_{model}$$

但 gated 版本会多出一条投影分支，因此参数量增加。如果还保持原来的 `4d_model`，整体 FFN 成本会变大太多。

所以工程上常见折中是：

$$d_{ff} \approx \frac{8}{3} d_{model}$$

这样 gated FFN 的总参数量与标准 `4d_model` FFN 维持在相近量级。

5.8 一个最小 SwiGLU 实现

```python
import torch
from torch import nn
import torch.nn.functional as F


class SwiGLU(nn.Module):
    def __init__(self, dim: int, hidden_dim: int):
        super().__init__()
        self.w1 = nn.Linear(dim, hidden_dim, bias=False)
        self.w_gate = nn.Linear(dim, hidden_dim, bias=False)
        self.w2 = nn.Linear(hidden_dim, dim, bias=False)

    def forward(self, x: torch.Tensor) -> torch.Tensor:
        return self.w2(F.silu(self.w1(x)) * self.w_gate(x))
```

5.9 这一节的现实结论

- ReLU、GeLU 都能做出好模型
- *GLU 不是绝对必要，但经验上通常是更好的默认项
- 如果没有特殊理由，现代开源 LLM 常从 SwiGLU 起步

6. Serial block 与 parallel block：块内并行到底值不值得

6.1 标准 block 是串行的

传统 block 往往是：

1. attention
2. 然后 MLP

即：

```
h = x + Attention(Norm(x))
y = h + MLP(Norm(h))
```

6.2 并行 block 的想法

parallel block 的思路是：

- 用同一个归一化输入同时喂给 attention 和 MLP
- 两个分支并行算
- 最后再合并

形式上更像：

```
n = Norm(x)
y = x + Attention(n) + MLP(n)
```

6.3 这样做的好处

slide 给出的理由包括：

- LayerNorm 可以共享
- 若实现得当，矩阵乘法可以更好融合
- 有潜在计算效率优势

它未必一定显著提升质量，但在系统层面可能更高效。

6.4 工程判断

这一点不像 pre-norm 那么“板上钉钉”。更准确地说：

- parallel block 是一种值得考虑的系统优化
- 但它不是所有现代 LLM 的默认铁律

如果你的目标是：

- 做一个稳妥、复现资料多的模型

那么串行 block 仍然是完全合理的起点。

7. 位置编码全景图：从绝对位置到相对位置

位置编码这一节是 lecture3 的重点之一，因为现代大模型在这件事上确实发生了明显收敛。

7.1 三大类位置编码

slide 把位置编码分成三大类：

1. 正弦余弦位置编码
2. 绝对位置向量
3. 相对位置编码

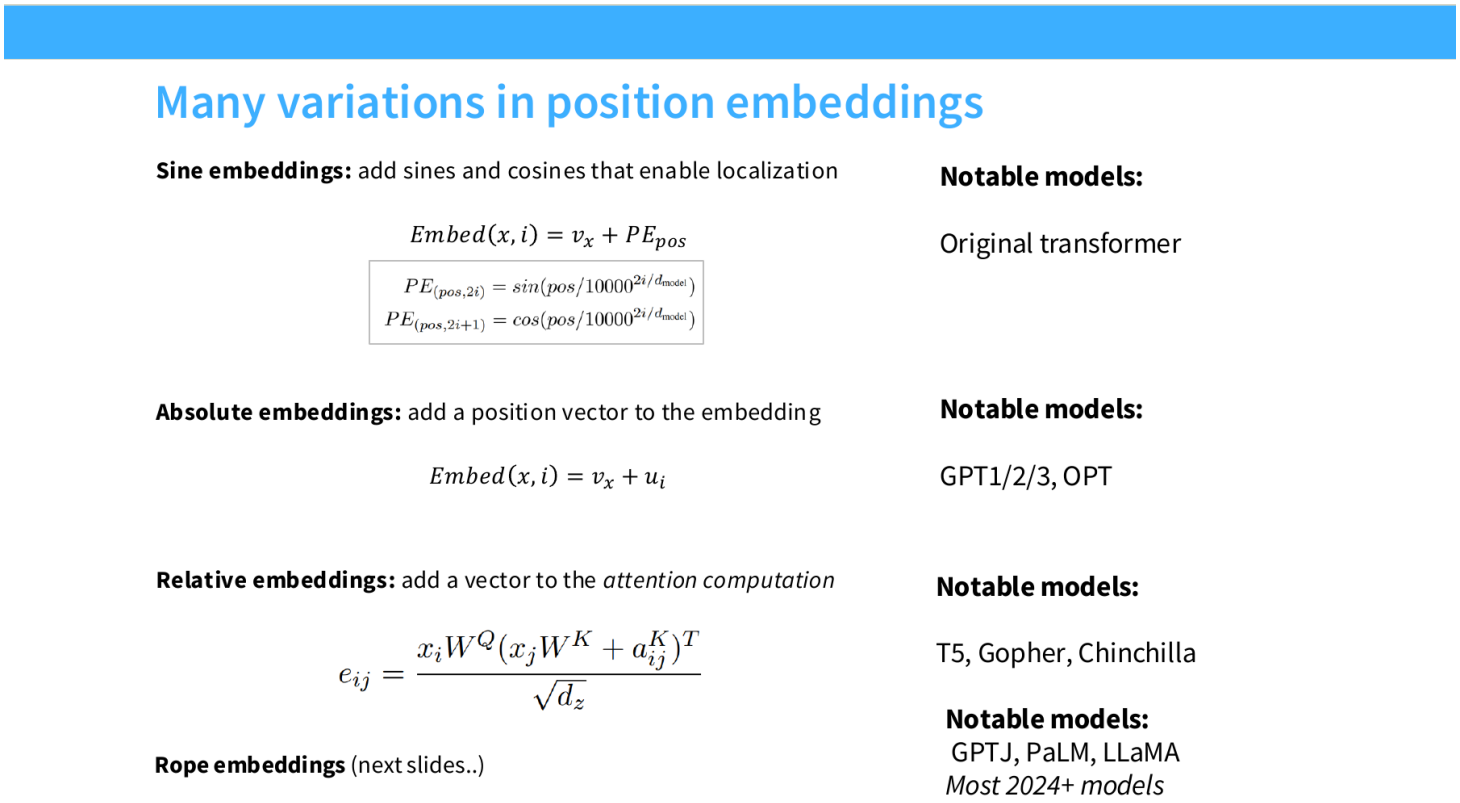

不过这里我没有直接插第 30 页截图，因为文中会把它拆开讲得更系统。

7.2 正弦余弦位置编码

经典写法是把一个固定函数 `PE(pos)` 加到 token embedding 上：

$$\mathrm{Embed}(x_i, i) = v_{x_i} + PE_i$$

优点：

- 不引入额外可学习位置参数
- 对更长位置有一定外推直觉

缺点：

- 对现代 decoder-only LLM 来说，往往不是最强默认项

7.3 绝对位置嵌入

做法更直接：

$$\mathrm{Embed}(x_i, i) = v_{x_i} + u_i$$

其中 `u_i` 是第 `i` 个位置的可学习向量。

优点：

- 简单
- 容易实现

缺点：

- 更依赖训练时见过的位置范围
- 对相对位置关系的表达不够“结构化”

7.4 相对位置编码

相对位置编码的目标是：

> attention 的位置依赖最好只与 `i - j` 有关，而不是与绝对位置 `i`、`j` 分别绑定。

这和语言建模中的很多归纳偏置是契合的，因为“离当前位置多远”通常比“绝对位于第 3821 个 token”更有意义。

8. RoPE：现代 LLM 最常见的位置编码

8.1 RoPE 想解决什么问题

RoPE 的核心目标是：

- 让注意力中的位置信息更自然地体现为相对位置信号
- 同时保留 inner product 计算结构

讲义的高层要求写成：

$$\langle f(x, i), f(y, j) \rangle = g(x, y, i - j)$$

也就是说：

- query/key 的相互作用最好只依赖相对位移 `i-j`

8.2 RoPE 的核心直觉：旋转

slide 用了一个非常直观的思路：

- 不去“加一个位置向量”
- 而是根据位置对 embedding 做旋转

因为：

> 内积在适当构造的旋转下，可以把绝对位置变成相对位移关系。

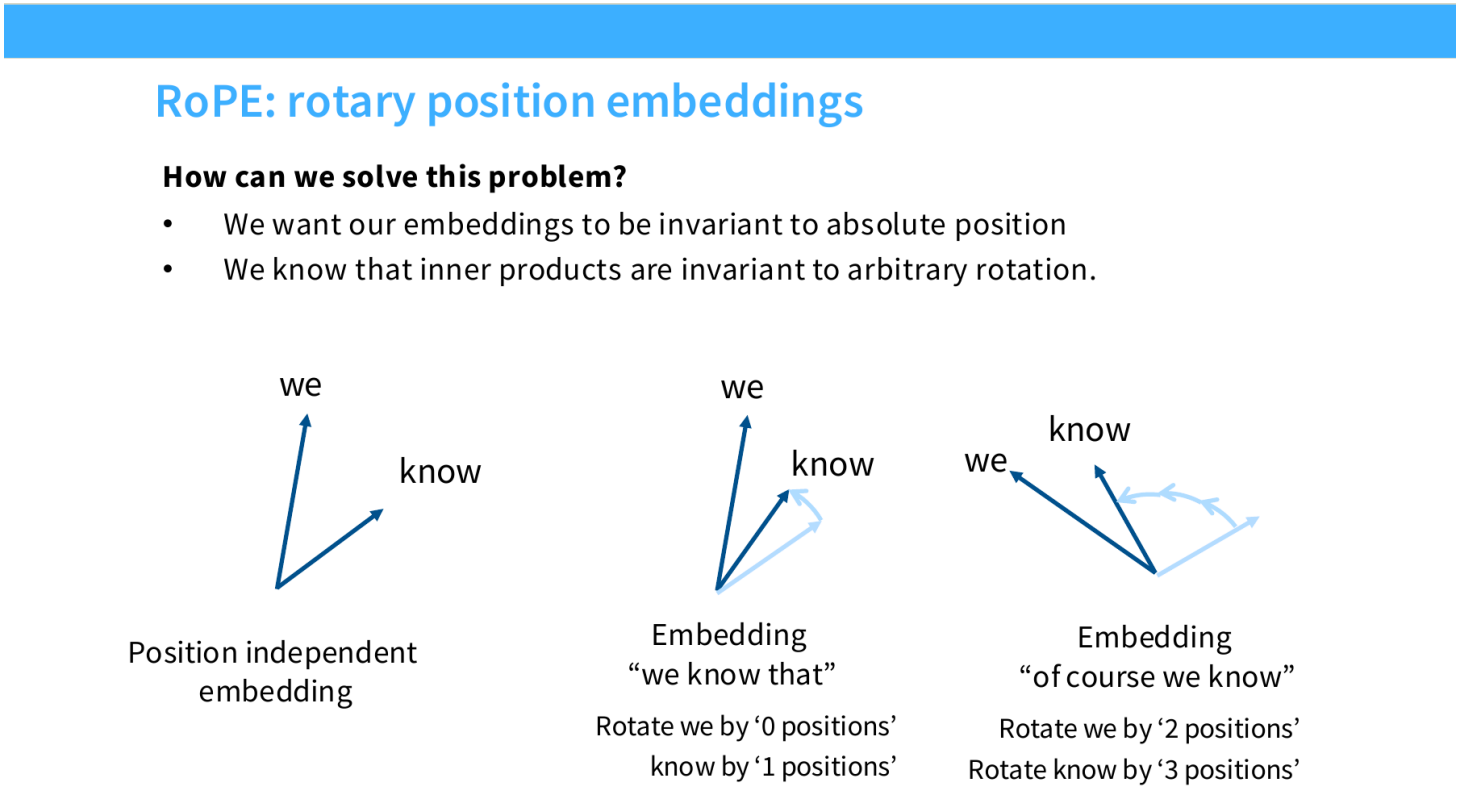

8.3 RoPE 怎么做旋转

RoPE 的做法是：

- 把 hidden 维按两两配对
- 每一对维度都看作二维平面中的一个向量
- 对每个位置 `m` 按特定角度旋转

这也是为什么很多解释会说：

- RoPE 可以从复数乘法的角度理解

8.4 RoPE 的数学形式

RoPE 的本质可以理解为：

$$q'_m = R_m q_m, \quad k'_n = R_n k_n$$

其中 `R_m` 是与位置 `m` 相关的块对角旋转矩阵。

slide 给出了更完整的矩阵形式：

The actual RoPE math

Multiply with sines and cosines

$$f_{\{q,k\}}(\boldsymbol{x}_m, m) = \boldsymbol{R}^d_{\Theta,m} \boldsymbol{W}_{\{q,k\}} \boldsymbol{x}_m \tag{14}$$

$$\boldsymbol{R}^d_{\Theta,m} = \begin{pmatrix} \cos m\theta_1 & -\sin m\theta_1 & 0 & 0 & \cdots & 0 & 0 \\ \sin m\theta_1 & \cos m\theta_1 & 0 & 0 & \cdots & 0 & 0 \\ 0 & 0 & \cos m\theta_2 & -\sin m\theta_2 & \cdots & 0 & 0 \\ 0 & 0 & \sin m\theta_2 & \cos m\theta_2 & \cdots & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & 0 & 0 & \cdots & \cos m\theta_{d/2} & -\sin m\theta_{d/2} \\ 0 & 0 & 0 & 0 & \cdots & \sin m\theta_{d/2} & \cos m\theta_{d/2} \end{pmatrix} \tag{15}$$

Difference with sine embeddings – not additive, no cross terms

这张图最重要的不是记住整个矩阵，而是记住两个结构性特征：

- 维度两两配对旋转
- 使用 `sin` 和 `cos`

8.5 RoPE 与正弦位置编码的关键区别

讲义特别强调：

- 正弦位置编码是“加法式”的
- RoPE 是“乘法 / 旋转式”的

这带来两个重要差别：

- 没有同样的 cross terms

- 更自然地作用在 attention 的 query/key 相互作用上

8.6 为什么 RoPE 会成为现代默认选择

经验上它有几个优点：

- 相对位置归纳偏置更自然
- 易于嵌入标准 attention 实现
- 与现代 decoder-only 架构搭配良好
- 在大量开源模型中已经成为默认经验

8.7 一个最小 RoPE 实现思路

下面给一个教学版写法，只展示核心张量变换思路：

```
import torch


def rotate_half(x: torch.Tensor) -> torch.Tensor:
    x1 = x[..., ::2]
    x2 = x[..., 1::2]
    return torch.stack([-x2, x1], dim=-1).flatten(-2)


def apply_rope(x: torch.Tensor, cos: torch.Tensor, sin: torch.Tensor) -> torch.Tensor:
    return x * cos + rotate_half(x) * sin
```

如果 `x` 的形状是：

```
[batch, heads, seq_len, head_dim]
```

那么：

- `cos` 和 `sin` 通常广播到同形状
- query 和 key 都要应用 RoPE
- value 一般不做 RoPE

8.8 RoPE 在 attention 中的位置

它通常发生在：

1. 输入投影出 `Q, K, V`
2. 对 `Q, K` 应用 RoPE
3. 再做注意力分数计算

伪代码：

```
q = q_proj(x)
k = k_proj(x)
v = v_proj(x)

q = apply_rope(q, cos, sin)
k = apply_rope(k, cos, sin)

att = softmax(q @ k.transpose(-2, -1) / sqrt(d))
out = att @ v
```

9. 超参数经验： `d_ff` 、head dim、深宽比例、词表大小

这一部分是 lecture3 非常有价值的地方，因为它给出了很多“不要过度神秘化”的结论。

9.1 `d_ff` 与 `d_model` 的关系

最常见经验法则：

$$d_{ff} = 4d_{model}$$

这是非常普遍的默认值。

9.2 如果用了 GLU，为什么常变成 `8/3 d_model`

前面已经说过，gated FFN 会多出一条门控分支，因此常常把 `d_ff` 缩到：

$$d_{ff} \approx \frac{8}{3} d_{model}$$

slide 里列了不少模型的实际比例，基本落在 `2.5` 到 `4` 附近。

Exception #1 – GLU variants

Remember that GLU variants scale down by 2/3rd. This means most GLU variants have $d_{ff} = \frac{8}{3} d_{model}$. This is mostly what happens. Some notable such examples.

Model	d_{ff}/d_{model}
PaLM	4
Mistral 7B	3.5
LLaMA-2 70B	3.5
LLaMA 70B	2.68
Qwen 14B	2.67
DeepSeek 67B	2.68
Yi 34B	2.85
T5 v1.1	2.5

Models are roughly in this range, though PaLM, LLaMA2 and Mistral are slightly larger

9.3 T5 为什么是著名例外

讲义特别点名 T5 的一个夸张例子：

- `d_ff = 65536`
- `d_model = 1024`

也就是：

$$d_{ff} = 64 d_{model}$$

这说明一件事：

- 超参数不是数学真理
- 极端设置也可能 work

但经验上，现代模型并没有因此普遍采用这种激进比例，所以它更像“例外证明不是完全不可能”，而不是默认建议。

9.4 `num_heads * head_dim` 是否必须等于 `d_model`

严格来说，不必须。

但实际中，大多数模型还是大致遵守：

$$\text{num_heads} \times \text{head_dim} \approx d_{model}$$

slide 列出的多个模型例子显示：

- 很多模型比例就在 1 左右
- 少数 Google 系模型偏大一些

How many heads, whats the model dim?

Some examples of this hyperparameter

	Num heads	Head dim	Model dim	Ratio
GPT3	96	128	12288	1
T5	128	128	1024	16
T5 v1.1	64	64	4096	1
LaMDA	128	128	8192	2
PaLM	48	258	18432	1.48
LLaMA2	64	128	8192	1

Most models have ratios around 1 – notable exceptions by some google models.

这一节想表达的是：

- 不要把这个关系神话成“必须成立”
- 但如果你没有特别强的理由，按它来通常是最稳妥的起点

9.5 模型应该更深还是更宽

slide 用 `d_model / n_layer` 这一类比值来展示现代模型的深宽比例。

Aspect ratios

Should my model be deep or wide? *How* deep and how wide?

Most models are surprisingly consistent on this one too!

Model	d_{model}/n_{layer}
BLOOM	205
T5 v1.1	171
PaLM (540B)	156
GPT3/OPT/Mistral/Qwen	128
LLaMA / LLaMA2 / Chinchila	102
T5 (11B)	43
GPT2	33

Sweet spot?

讲义给出的结论比较现实：

- 很深的模型更难并行
- latency 往往更高
- 系统约束会强烈影响“最佳”深宽比例

所以这不是一个纯理论问题，而是：

- 算法
- 并行策略
- 硬件
- 目标服务延迟

一起决定的。

9.6 词表应该多大

讲义给出的经验非常实用：

- 单语模型：常见 `30k - 50k`
- 多语或生产系统：常见 `100k - 250k`

这背后反映的是 tokenization trade-off：

- 词表太小：序列更长
- 词表太大：embedding / softmax 更重、训练和部署更贵

所以词表大小本质上不是“越大越先进”，而是：

- 服务语言范围
- token 碎片化程度
- 系统成本

三者之间的折中。

9.7 这一节最值得记住的态度

lecture3 对超参数问题的总体态度并不是“给你唯一正确答案”，而是：

- 现代大模型其实有很多保守而重复出现的默认值
- 真正的异常值很少
- 如果你不是在做很激进的探索，先站在这些默认值上更合理

10. 正则化与稳定训练：dropout、weight decay、z-loss、QK norm

10.1 大模型预训练还需要 regularization 吗

直觉上很多人会说：

- 数据很多
- 只扫一遍语料
- 好像不容易过拟合

这确实有一定道理，但 slide 给出的实际观察是：

- 不是完全不 regularize
- 只是 regularization 的角色更像优化动力学控制，而不只是防过拟合

10.2 dropout 与 weight decay 的现实趋势

讲义展示了多个模型的做法：

- 较老模型更常用 dropout
- 较新模型往往更依赖 weight decay
- 一些新模型预训练时直接不做 dropout

Dropout and weight decay in practice

Model	Dropout*	Weight decay
Original transformer	0.1	0
GPT2	0.1	0.1
T5	0.1	0
GPT3	0.1	0.1
T5 v1.1	0	0
PaLM	0	(variable)
OPT	0.1	0.1
LLaMA	0	0.1
Qwen 14B	0.1	0.1

Many older models used dropout during pretraining

Newer models (except Qwen) rely only on weight decay

* Most of the times papers just don't discuss dropout. On open models, this closely matches not doing dropout. This may not be true of closed models.

这说明：

- dropout 不是现代 LLM 预训练的绝对默认项
- weight decay 仍然很常见

10.3 为什么 weight decay 在这里不是“防过拟合教科书故事”

讲义特别提醒：

> 在 LLM 里，weight decay 的作用并不只是控制过拟合。

它还会与：

- learning rate schedule
- cosine decay
- 参数尺度演化

发生复杂交互，因此更像一个优化动态调节项。

10.4 训练稳定性为什么总绕不开 softmax

这一节后半部分是稳定性 tricks，核心警告是：

> 小心 softmax。

因为 softmax 涉及：

- 指数
- 归一化
- 数值范围极易放大

不稳定通常发生在两个地方：

1. 输出层 softmax
2. attention 内部的 softmax

10.5 z-loss 是什么

z-loss 是对输出 logits 稳定性的一个 trick。它的目标不是替代交叉熵，而是：

- 约束 logits 尺度
- 缓解数值异常
- 改善训练稳定性

slide 中提到 PaLM 使用了这个技巧，后续也有若干模型跟进。

你可以把它理解成：

- 给 softmax 前的 logits 再加一个稳定性辅助约束

10.6 QK norm 是什么

QK norm 的做法是：

- 在进入 attention softmax 之前
- 先对 query 和 key 做 norm

也就是：

```
q = q_norm(q)
k = k_norm(k)
scores = q @ k.transpose(-2, -1)
```

它的目标很明确：

- 不要让 `qk^T` 的数值范围失控
- 让注意力 softmax 更稳定

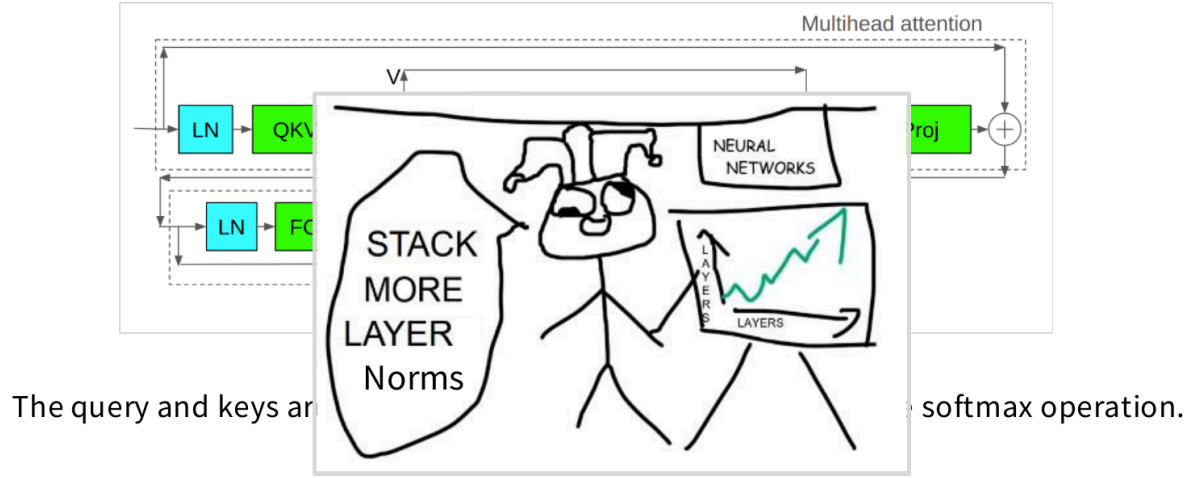

10.7 logit soft-capping

另一个更直接的做法是：

- 用 `tanh` 或类似方式把 logits 限幅

好处：

- 防止 logits 爆炸

代价：

- 可能影响表达能力
- 也可能引入性能权衡

10.8 稳定训练的真实含义

这节真正想表达的是：

- 大模型训练不稳定，不一定是你代码写错了

- 可能是架构和数值设计没有把风险点压住

现代稳定性 trick 的大方向是：

- 避免主残差流被过度扰动
- 控制 softmax 相关数值范围
- 让优化过程更平滑

11. 注意力推理优化：KV cache、MQA、GQA、滑动窗口注意力

这一部分非常重要，因为它回答的是：

> 为什么很多 attention 变体的目标其实不是训练更准，而是推理更省。

11.1 训练时 attention 和推理时 attention 不是同一个系统问题

训练时：

- 可以并行处理整个序列
- arithmetic intensity 通常还不错

推理时：

- token 必须一步一步生成
- 不能像训练那样完全并行
- 于是 KV cache 的搬运和读取开始变成核心成本

11.2 KV cache 为什么重要

增量解码时，如果每生成一个 token 都重新算完整历史 attention，会非常浪费。

所以通常会缓存：

- past keys
- past values

这就是 KV cache。

它的价值在于：

- 避免重复计算历史 K/V
- 让每一步只新增一个 token 的 K/V

但它也带来一个新瓶颈：

- 你必须反复从显存里读取越来越长的 KV cache

11.3 MQA：为什么要减少 key/value 头数

MQA 的核心思想是：

- query 仍然多头
- key/value 不再每个 head 各一份
- 而是共享得更多

这样做的直接收益是：

- KV cache 更小
- 推理时内存读写更少
- 解码吞吐更高

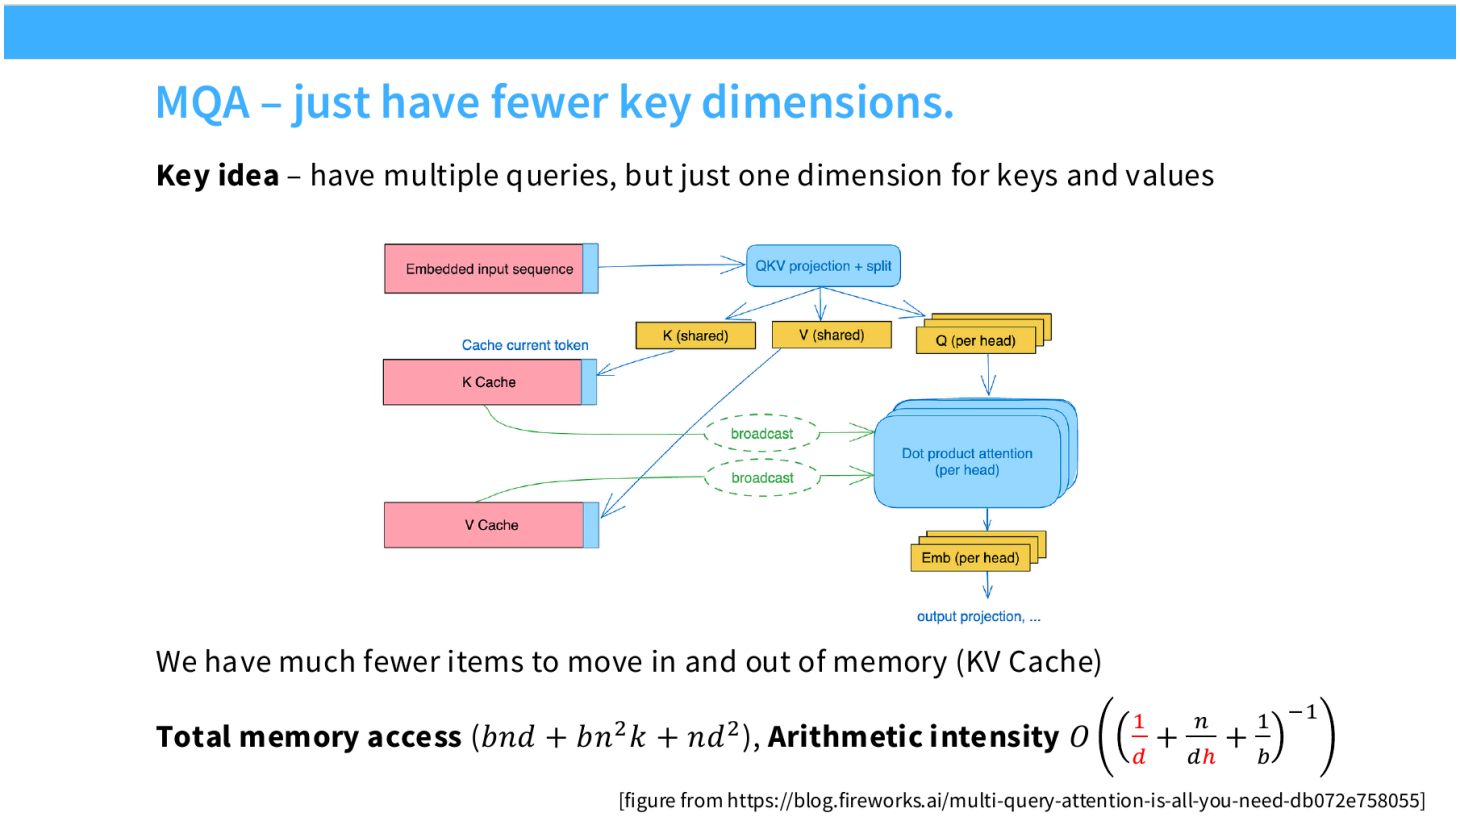

[figure from https://blog.fireworks.ai/multi-query-attention-is-all-you-need-db072e758055]

11.4 为什么 MQA 有时会伤性能

因为它本质上在做一种表达能力压缩：

- query 头很多
- 但 K/V 表达更少样

讲义提到：

- MQA 可能有小幅 PPL 损失
- GQA 往往能在效率和表达之间取得更好平衡

11.5 GQA：在 MHA 和 MQA 之间折中

GQA 的做法是：

- 不像 MHA 那样每个 query head 都有独立 K/V
- 也不像 MQA 那样全都共享一套 K/V
- 而是若干 query head 共享一组 K/V

因此它是一个更柔和的折中：

- 比 MHA 省缓存
- 比 MQA 更保留表达能力

11.6 滑动窗口注意力为什么出现

全局注意力的成本是二次的。对于超长上下文，很多时候没必要每层都看完整历史。

所以会出现：

- sparse attention
- sliding window attention

其核心思想是：

- 每层只看局部窗口或结构化子集
- 利用网络深度逐层传播更远信息

11.7 为什么现代模型会交替使用 full attention 与 local attention

slide 末尾提到了一种很实用的设计：

- 大多数层使用更便宜的局部注意力
- 每隔几层插一个 full attention

这样做的目的：

- 保留长程信息通路
- 降低平均计算和访存成本

11.8 一个最小 GQA 形状示意

如果是标准多头注意力，可能是：

```
q.shape = [B, Hq, T, Dh]
k.shape = [B, Hq, T, Dh]
v.shape = [B, Hq, T, Dh]
```

而 GQA 里往往是：

```
q.shape = [B, Hq, T, Dh]
k.shape = [B, Hkv, T, Dh]
v.shape = [B, Hkv, T, Dh]
```

其中：

- `Hkv < Hq`

再通过 head grouping 把多个 query head 对应到同一组 K/V。

12. 如果今天自己做一个现代 LM，默认怎么选

结合 lecture3 的整体倾向，如果今天你要做一个“稳妥的现代 dense decoder-only LM”，在没有特别研究目标时，一个合理的默认起点大概是：

12.1 架构默认项

- pre-norm
- RMSNorm
- 无 bias 的线性层
- RoPE
- SwiGLU
- 常规串行 block，除非你特别关心系统优化

12.2 超参数默认项

- `d_ff = 4d_model`
- 如果用 GLU， `d_ff ≈ 8/3 d_model`
- `num_heads * head_dim ≈ d_model`
- 词表大小按语种和服务场景保守选取
- 深宽比例先贴近已有成功模型

12.3 训练默认项

- 不迷信 dropout
- 合理使用 weight decay
- 关注 softmax 稳定性
- 必要时考虑 z-loss、QK norm 或其他 logit 控制手段

12.4 推理默认项

- 长上下文和高吞吐部署场景下，优先考虑 GQA
- 需要进一步压缩时再考虑更激进的 MQA
- 超长序列场景下考虑 sliding window / hybrid attention

13. 高频考点与常见误区

13.1 高频结论

- 几乎所有现代 LLM 都偏向 pre-norm
- RMSNorm 是非常常见的现代选择
- 去 bias 是常见工程简化
- SwiGLU / GeGLU 是近年高频默认项
- RoPE 已成为大量现代 LLM 的标准位置编码
- `d_ff = 4d_model` 仍是最稳的默认经验
- 使用 GLU 时 `d_ff` 常缩到约 `8/3 d_model`
- 推理优化里，MQA/GQA 的核心目标是降低 KV cache 访存成本
- dropout 在新模型预训练中并不总是默认开启
- 稳定训练常常需要关注 softmax 数值行为

13.2 常见误区

误区 1：只要 FLOPs 低，运行一定更快

错。很多真实瓶颈来自 memory movement 和 kernel 效率。

误区 2：post-norm 只是另一种同样流行的写法

错。现代 dense LLM 中它已经明显不是主流默认项。

误区 3：RoPE 只是“另一种可学习位置向量”

错。RoPE 的核心是旋转式、相对位置结构，而不是简单相加。

误区 4：MQA/GQA 是为了训练更准

通常不是。它们的主要价值是推理效率，尤其是 KV cache 相关成本。

误区 5：dropout 越多越稳

错。现代大模型预训练里，dropout 并不是无脑默认增益项。

14. 附：最小代码实现片段

这一节不给完整 Transformer，只给 lecture3 最相关的几个组件。

14.1 RMSNorm

```
import torch
from torch import nn


class RMSNorm(nn.Module):
    def __init__(self, dim: int, eps: float = 1e-6):
        super().__init__()
        self.eps = eps
        self.weight = nn.Parameter(torch.ones(dim))

    def forward(self, x: torch.Tensor) -> torch.Tensor:
        return x * torch.rsqrt(x.pow(2).mean(dim=-1, keepdim=True) + self.eps) * self.we
```

14.2 SwiGLU

```python
import torch
import torch.nn.functional as F
from torch import nn


class SwiGLU(nn.Module):
    def __init__(self, dim: int, hidden_dim: int):
        super().__init__()
        self.w1 = nn.Linear(dim, hidden_dim, bias=False)
        self.w_gate = nn.Linear(dim, hidden_dim, bias=False)
        self.w2 = nn.Linear(hidden_dim, dim, bias=False)

    def forward(self, x: torch.Tensor) -> torch.Tensor:
        return self.w2(F.silu(self.w1(x)) * self.w_gate(x))
```

14.3 RoPE

```python
import torch


def rotate_half(x: torch.Tensor) -> torch.Tensor:
    x1 = x[..., ::2]
    x2 = x[..., 1::2]
    return torch.stack((-x2, x1), dim=-1).flatten(-2)


def apply_rope(x: torch.Tensor, cos: torch.Tensor, sin: torch.Tensor) -> torch.Tensor:
    return x * cos + rotate_half(x) * sin
```

14.4 pre-norm block 骨架

```python
class PreNormBlock(nn.Module):
    def __init__(self, dim, attn, ffn):
        super().__init__()
        self.norm1 = RMSNorm(dim)
        self.norm2 = RMSNorm(dim)
        self.attn = attn
        self.ffn = ffn

    def forward(self, x):
        x = x + self.attn(self.norm1(x))
        x = x + self.ffn(self.norm2(x))
        return x
```

14.5 一个 lecture3 风格的“现代默认配置”

```python
modern_defaults = {
    "norm": "RMSNorm",
    "residual_order": "pre-norm",
    "activation": "SwiGLU",
    "position_embedding": "RoPE",
    "linear_bias": False,
    "attn_variant": "MHA or GQA depending on inference budget",
}
```

15. 一句话总结构图

如果只用一句话概括 lecture3：

> 现代大语言模型的主流演化方向，并不是推翻 Transformer，而是在归一化、FFN、位置编码、稳定性和推理成本这些细节上，逐步形成一套偏向 pre-norm、RMSNorm、RoPE、SwiGLU 与高效 attention 变体的工程共识。