CS336 Lecture 4 学习讲义

> 副标题：Mixture of Experts 的架构、路由、训练稳定性与系统代价
>
> 适用对象：正在上 CS336 的课程同学
>
> 依据材料：2025 Lecture 4 - MoEs.pdf

目录

1. 这节课在讲什么
2. 什么是 MoE：从 dense FFN 到 sparse expert layer
3. 为什么 MoE 重新流行
4. 一个现代 LLM 的 MoE 层长什么样
5. Routing：MoE 的核心
6. 为什么训练 MoE 很难
7. Load balancing、稳定性与训练技巧
8. 系统与基础设施视角下的 MoE
9. 近期代表性设计：Switch、Mixtral、Qwen、DeepSeek、OlMoE
10. 如果今天自己做一个 MoE，该默认怎么想
11. 高频考点与常见误区
12. 附：最小 MoE 代码骨架
13. 一句话总结构图

1. 这节课在讲什么

`lecture2` 讲的是训练一个模型最底层需要哪些 primitive：张量、内存、FLOPs、优化器、训练循环。`lecture3` 讲的是现代 dense Transformer 的主流架构共识：pre-norm、RMSNorm、RoPE、SwiGLU、若干稳定性与推理优化技巧。

而 `lecture4` 讨论的是一个更进一步的问题：

> 如果我不想让每个 token 都走完整个 dense 模型，而是希望“只激活一部分参数”，那我该怎么设计模型？

这就是 Mixture of Experts（MoE）的核心问题。

这节课不是在讲一个“完全不同于 Transformer 的模型家族”，而是在讲一种重要扩展：

- Transformer 主体结构仍保留
- 但 FFN 不再是单一 dense MLP
- 而是变成“多个 expert + 一个 router”

这会带来一系列新的问题：

- 为什么参数量可以大幅增加，但 FLOPs 不一定同步增加
- 路由怎么做
- 为什么离散路由很难训练
- 为什么 load balancing 几乎成了 MoE 的生命线
- 为什么 MoE 很强，但基础设施更复杂

从课程主线看，这一讲相当于把“现代 dense LLM”的架构讨论推进到：

- **稀疏激活（sparsity）**
- **条件计算（conditional computation）**
- **跨设备系统设计**

这几件事上。

2. 什么是 MoE：从 dense FFN 到 sparse expert layer

2.1 最核心的结构替换

MoE 的最典型做法并不是把整个 Transformer 都改掉，而是把 block 中的 FFN 部分替换掉。

在标准 dense Transformer block 里，你通常有：

```
x = x + Attention(Norm(x))
x = x + FFN(Norm(x))
```

而在典型的 MoE Transformer block 中，第二项会变成：

```
x = x + Attention(Norm(x))
x = x + MoE(Norm(x))
```

也就是说：

- attention 通常还是 dense 的
- 被稀疏化的主要是 FFN

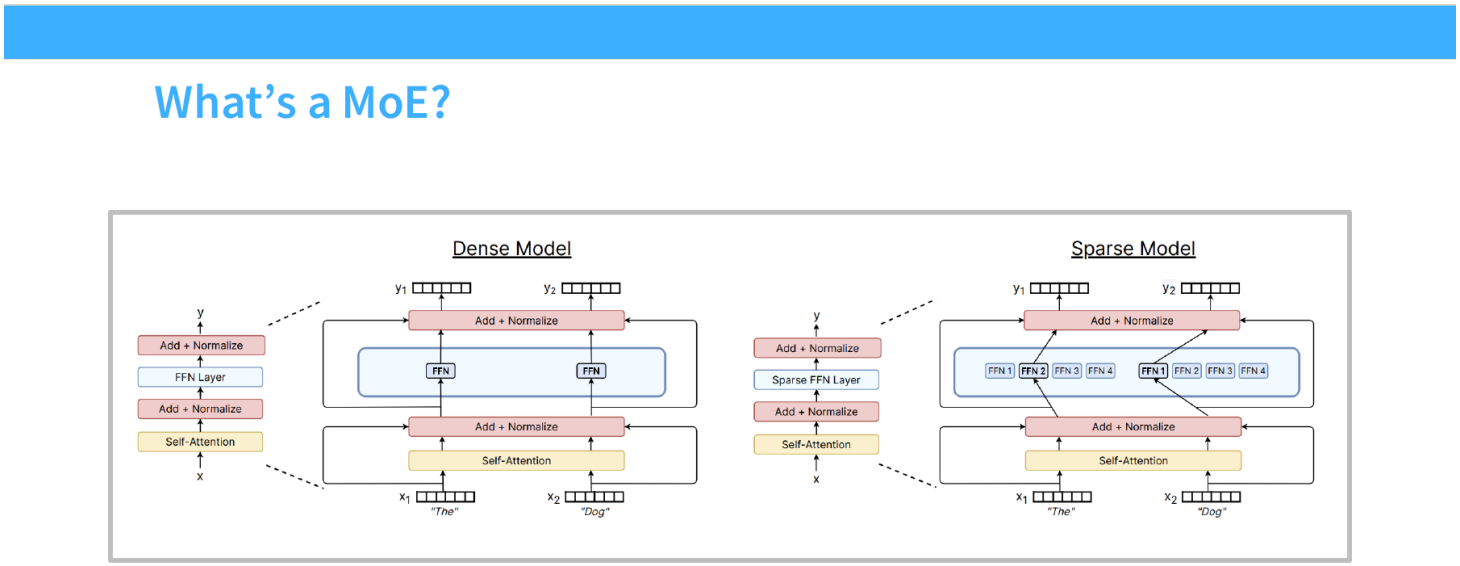

这张图其实就包含了 MoE 最重要的一句话：

> 用很多个大前馈网络（experts）替代一个大前馈网络，再加一个 selector / router 决定每个 token 走哪些 expert。

2.2 为什么“参数更多但 FLOPs 不一定更多”

这是很多人第一次接触 MoE 时最容易误解的点。

如果你有：

- 1 个大 FFN

改成：

- 64 个大 FFN expert

看起来参数量会膨胀很多。但真正的关键是：

- 每个 token **不会**走所有 64 个 expert
- 它只会被 router 分配给其中少数几个

例如：

- 总共有 64 个 expert
- 但每个 token 只激活 top-2

那么：

- 总参数量非常大
- 但单个 token 实际参与的计算量仍然只对应少量 active experts

这就是 MoE 的本质：

> 用更大的“总模型容量”换取接近不变的“单 token 计算量”。

2.3 一个最小直觉例子

假设一个 dense FFN 需要：

- 一次 `d_model -> d_ff`
- 一次 `d_ff -> d_model`

如果你把它复制成 16 个 expert：

- 总参数量大约会膨胀 16 倍

但如果每个 token 只走 2 个 expert：

- token 级 FLOPs 只近似变成原来的 2 倍（再加上路由开销）
- 而不是 16 倍

这也是为什么人们会说：

- MoE 是一种“用稀疏激活换更大参数规模”的办法

2.4 稠密模型和稀疏模型的直觉差别

可以把二者粗略理解成：

Dense 模型

- 每个 token 都走同一套参数
- 简单、稳定、容易实现

MoE 模型

- 不同 token 走不同 expert 子网络
- 参数容量更大
- 但计算路径更复杂，训练和系统都更难

所以 MoE 不是白拿收益，而是在进行一种明确的 trade-off：

- 更大总容量
- 更复杂路由
- 更高系统复杂度

3. 为什么 MoE 重新流行

lecture4 前面连续几页都在回答同一个问题：

> MoE 不是新东西，为什么它这几年突然又变热了？

答案大致可以归成三类。

3.1 同样 FLOPs 下，更多参数往往更强

slide 中最核心的动机之一是：

> 在相近 FLOPs 预算下，更多参数的 MoE 往往优于 dense 对照模型。

这非常符合 MoE 的直觉：

- dense 模型受限于“所有参数每次都必须被激活”
- MoE 则允许你把总容量做得更大，但每次只用一部分

因此在相同训练算力预算下，MoE 有可能获得更强的表示能力。

3.2 MoE 往往训练更快，至少在合适的系统条件下如此

slide 中还给出另一个很重要的经验观察：

- MoE 往往能更快达到某个目标性能

这不是说它每一步都无条件更快，而是说：

- 在多卡、多机、适当并行与稀疏实现良好的情况下
- 它可能以更低的训练成本达到相近甚至更好的性能

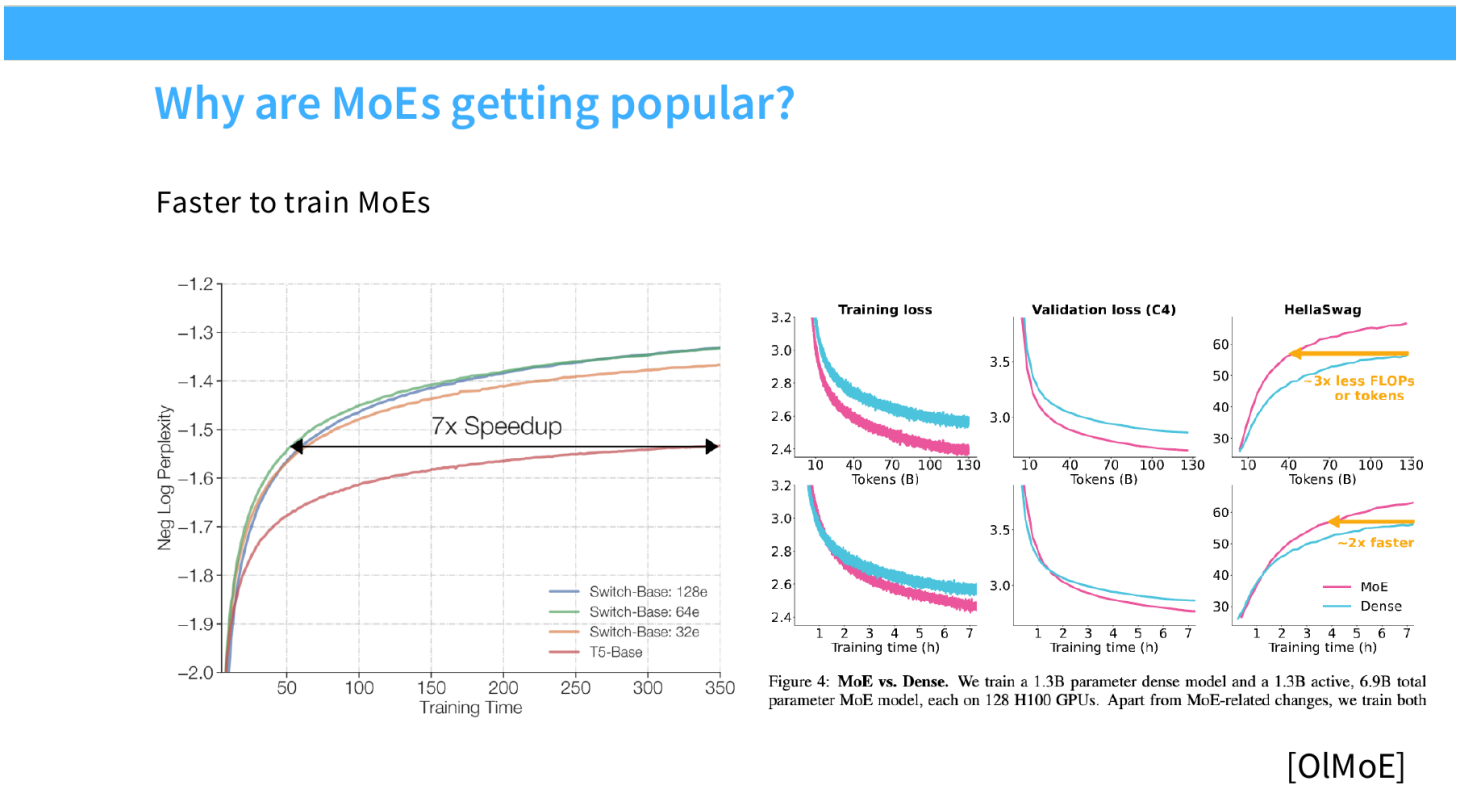

[OlMoE]

3.3 MoE 对大规模并行更友好

MoE 之所以吸引工业界，还有一个很现实的原因：

- 它天然适合跨更多设备扩展 expert 容量

因为：

- 不同 expert 可以部署在不同设备上
- 不需要所有参数同时参与每个 token 的计算

从系统视角看，它是一种很适合横向扩容参数容量的架构。

3.4 开源与闭源模型都在给出越来越多正面证据

lecture4 还强调了一个事实：

- 不只是某一两个模型在用 MoE

- 近年的高性能模型里，MoE 越来越常见

包括：

- 西方开源模型中的强模型
- 中国厂商的 Qwen / DeepSeek 系列
- 以及更系统化的 MoE ablation 工作

这意味着：

> MoE 不再只是“某个实验室的架构怪招”，而是已经积累了足够多的经验性支持。

3.5 但它没有更早普及，也不是没有原因

slide 也马上提醒了另一面：

- 基础设施复杂
- 优势更多体现在多机多卡
- 训练目标带有启发式成分
- 有时不稳定

也就是说，MoE 并不是“免费午餐”，它只是：

- 在今天的大规模训练环境中
- 变得越来越值得这份复杂度

4. 一个现代 LLM 的 MoE 层长什么样

4.1 典型位置：替换 MLP，不替换 attention

现代 LLM 中最典型的 MoE 做法是：

- 保留 self-attention 为 dense
- 把 block 中的 MLP / FFN 换成 MoE layer

这是最重要的默认认知。

What MoEs generally look like

Typical: replace MLP with MoE layer

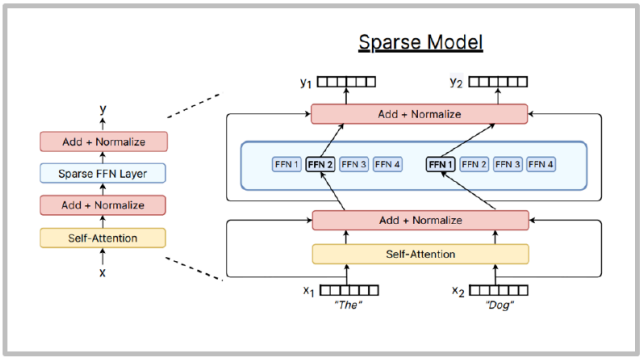

Less common: MoE for attention heads

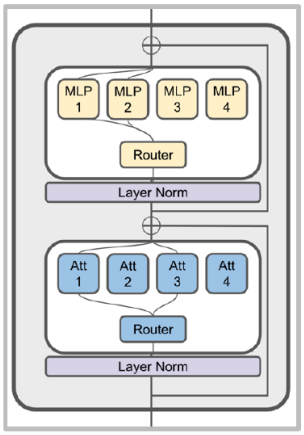

[ModuleFormer, JetMoE]

虽然 slide 也提到：

- attention heads 上做 MoE 也存在

但这不是主流路径。

4.2 一个最小 MoE 层的逻辑

给定输入 hidden states：

```
u = Norm(x)
```

MoE 层通常做下面几步：

1. router 给每个 token 计算所有 expert 的分数
2. 选 top-k 个 expert
3. 把 token 分发给这些 expert
4. expert 各自执行 FFN
5. 把 expert 输出按 gate 权重聚合回来

伪代码可以写成：

```
scores = router(u)                    # [tokens, num_experts]
topk_idx, topk_weight = topk(scores)  # 每个 token 只选 k 个 expert

outputs = 0
for e in selected_experts:
    outputs += gate[token, e] * expert_e(u_token)
```

4.3 shared experts 是什么

lecture4 提到近年一个很有代表性的变化：

- 除了 routed experts
- 还会加少量 shared experts

shared experts 的特点是：

- 它们总是开启
- 不依赖 router 做稀疏选择

直觉上，你可以把它理解成：

- 给所有 token 一条共同的“保底 dense 通路”
- 再额外加上 routed experts 提供更细粒度的 specialization

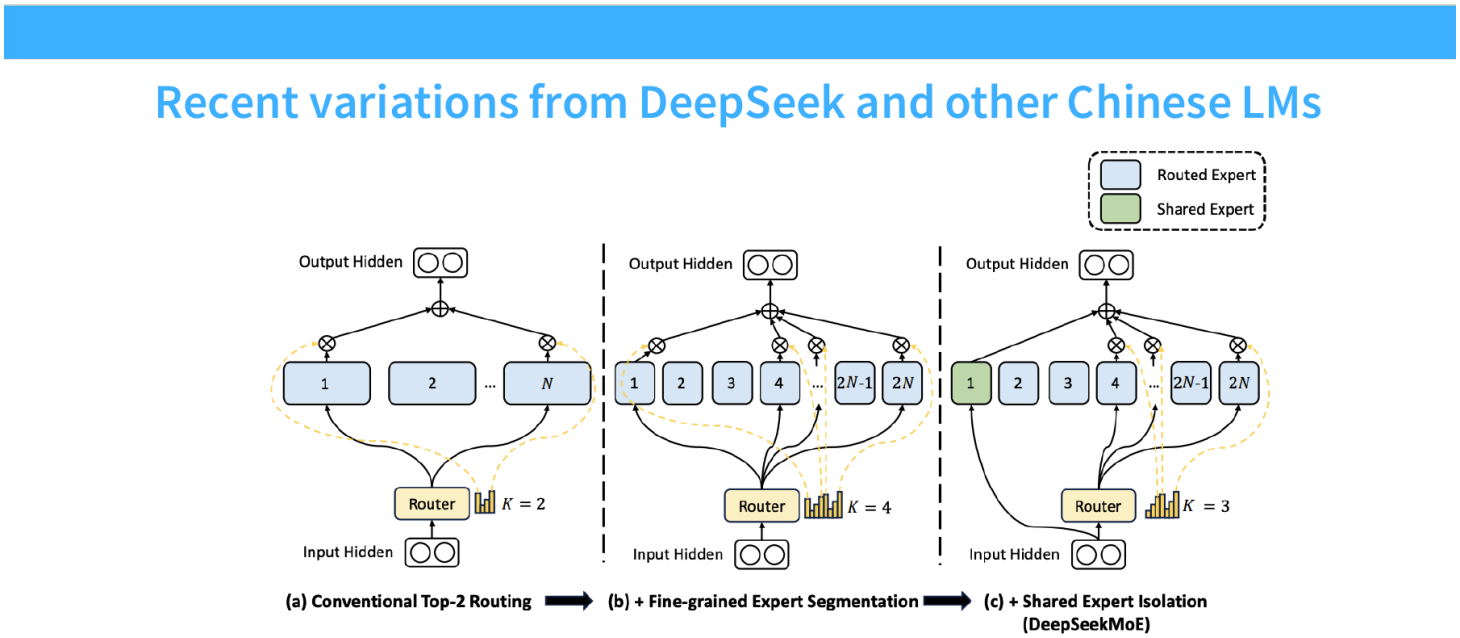

Smaller, larger number of experts + a few shared experts that are always on.

(Used in DeepSeek / Qwen, originally from DeepSpeed MoE)

4.4 fine-grained experts 是什么

lecture4 里另一个关键词是：

- fine-grained experts

它表示：

- expert 数量更多
- 每个 expert 本身更小更细

这样会产生一种新的设计趋势：

- 不再是少数几个“大专家”
- 而是更多、更细粒度的专家

这种设计常见于 DeepSeek、Qwen 一类近期架构。

4.5 routed / active / shared 这三个数要区分开

MoE 论文里常见几个数字：

- `Routed experts`：总共有多少个可路由专家
- `Active experts`：每个 token 实际激活多少个专家
- `Shared experts`：始终开启的共享专家有多少个

这三个数必须分清，因为它们对应不同资源维度：

- routed：总容量
- active：每 token 实际 FLOPs
- shared：统一通路和额外 dense 负担

Expert routing setups for recent MoEs

Model	Routed	Active	Shared	Fine-grained ratio
GShard	2048	2	0	
Switch Transformer	64	1	0	
ST-MOE	64	2	0	
Mixtral	8	2	0	
DBRX	16	4	0	
Grok	8	2	0	
DeepSeek v1	64	6	2	1/4
Qwen 1.5	60	4	4	1/8
DeepSeek v3	256	8	1	1/14
OlMoE	64	8	0	1/8
MiniMax	32	2	0	~1/4
Llama 4 (maverick)	128	1	1	1/2

这张表最重要的启发不是记住每个模型的具体数字，而是看出趋势：

- routed experts 总数在不断增大
- active experts 通常保持在较小范围
- shared experts 是否有用，并没有完全共识

4.6 一个现代 MoE block 的心智模型

如果把 dense Transformer block 和 MoE Transformer block 做对照，可以这样记：

Dense

```
x = x + Attention(Norm(x))
x = x + FFN(Norm(x))
```

MoE

```
x = x + Attention(Norm(x))
x = x + SharedExperts(Norm(x)) + RoutedExperts(Norm(x))
```

不同论文细节会不同，但大方向就是：

- 用 sparse routed experts 扩总容量

- 用少量 shared path 稳住基础表达

5. Routing：MoE 的核心

MoE 真正的灵魂不在“很多个 FFN”本身，而在：

> 谁决定每个 token 应该去哪个 expert?

这个决策机制就是 routing。

5.1 routing 的三大类思路

lecture4 把 routing 粗略分成三类：

1. token chooses expert
2. expert chooses token
3. global routing via optimization

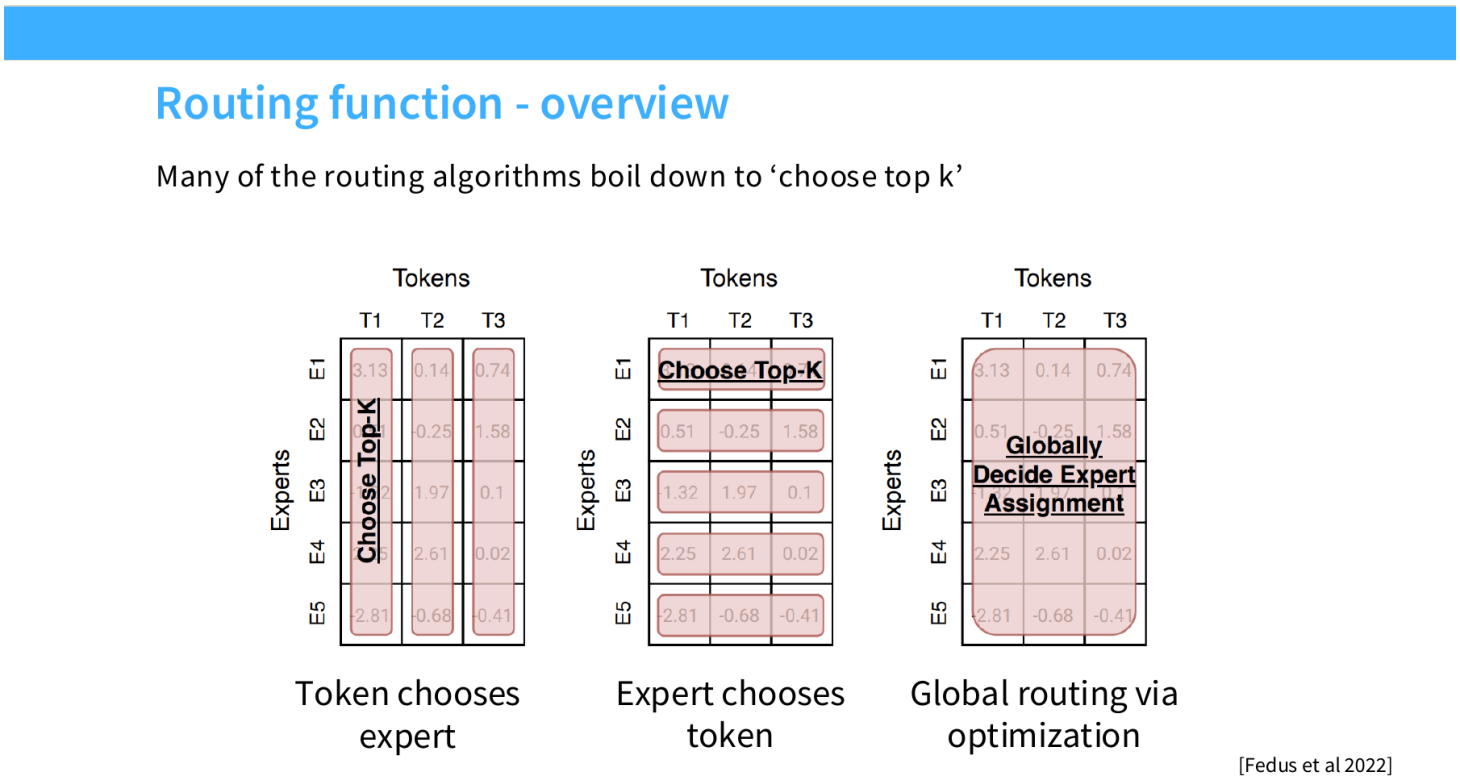

但实践里几乎所有现代大模型最终都收敛到第一类：

- token-choice top-k routing

5.2 为什么 top-k routing 成了现实默认值

因为它同时满足三件事：

1. 足够简单
2. 足够高效
3. 虽然启发式，但效果已经足够好

换句话说，top-k 不是“最优理论方案”，而是：

- 目前综合工程可行性和经验效果最好的方案

5.3 top-k routing 的基本形式

给定 token 表示 u_t，router 会为每个 expert 打分：

$$s_{i,t} = f(u_t, e_i)$$

然后从这些分数中选出 top-k experts。
若 expert i 在 top-k 里，则其 gate 权重为：

$$g_{i,t} = s_{i,t}$$

否则：

$$g_{i,t} = 0$$

最终 token 的输出可写成：

$$h_t = \sum_i g_{i,t} \, \mathrm{FFN}_i(u_t) + u_t$$

5.4 DeepSeek / Grok / Qwen 风格 vs Mixtral / DBRX / DeepSeek v3 风格

lecture4 还提到一个细节分歧：

- 有些模型在选出 top-k 之前就做 softmax
- 有些模型是 top-k 之后再 softmax

这不是表面差异，它会影响：

- gate 权重的归一化方式
- 被选 expert 之间的相对权重解释

Top-K routing in detail.

Most papers do the old and classic top-k routing. How does this work?

Gating

$$\mathbf{h}_t^l = \sum_{i=1}^{N} \left(g_{i,t} \operatorname{FFN}_i \left(\mathbf{u}_t^l \right) \right) + \mathbf{u}_t^l,$$

$$g_{i,t} = \begin{cases} s_{i,t}, & s_{i,t} \in \operatorname{Topk}(\{s_{j,t} | 1 \leqslant j \leqslant N\}, K), \\ 0, & \text{otherwise}, \end{cases}$$

$$s_{i,t} = \operatorname{Softmax}_i \left(\mathbf{u}_t^{l^T} \mathbf{e}_i^l \right),$$

Gates selected by a logistic regressor

This is the DeepSeek (V1-2) router (Grok, Qwen do this too)

Mixtral, DBRX, DeepSeek v3 softmaxes after the TopK

[Dai et al 2024]

5.5 top-1、top-2、top-4、top-8 代表什么

这些数字表示：

- 每个 token 被送去多少个 routed experts

例如：

- Switch Transformer： `k = 1`
- Mixtral： `k = 2`
- DBRX： `k = 4`
- DeepSeek v3：更多 routed experts，但 active experts 仍保持较小值

这个参数直接影响：

- 每 token FLOPs
- expert specialization 程度
- 聚合稳定性

5.6 其他 routing 方法为什么不够主流

lecture4 也列出了其他几类做法：

- hash routing

- reinforcement learning 路由
- matching / assignment routing

但它们的问题通常是：

- 系统更复杂
- 优化更难
- 不一定带来足够大收益

这也是为什么你在大多数现代开源 MoE 里看到的仍然是：

- top-k

5.7 一个最小 top-k router 示例

```
import torch


def topk_route(x, router_w, k):
    # x: [tokens, d_model]
    # router_w: [num_experts, d_model]
    scores = x @ router_w.T
    values, indices = torch.topk(scores, k=k, dim=-1)
    weights = torch.softmax(values, dim=-1)
    return indices, weights
```

这个实现很简化，但足够表达 top-k router 的核心：

- 先算所有 expert 分数
- 再做 top-k
- 再在被选专家之间归一化

6. 为什么训练 MoE 很难

lecture4 中最重要的一张“问题定义”页之一是这句话：

> 我们需要稀疏路由，才能在训练时高效；但稀疏门控决策本身又是不可导的。

这就是 MoE 训练的核心张力。

6.1 稀疏性是 MoE 的价值来源

如果你不做稀疏选择，而是让每个 token 都经过所有 expert：

- 那就几乎退化成把很多 FFN 全部算一遍
- FLOPs 会大幅上升
- MoE 失去最重要的效率意义

所以 MoE 必须依赖：

- 离散、稀疏的 expert 选择

6.2 但离散选择不容易反向传播

top-k 本质上是离散操作。
离散决策通常对梯度不友好，因为：

- argmax / top-k 不是平滑函数
- 被丢掉的路径没有自然梯度

所以从优化角度看，MoE 从一开始就带着一个麻烦：

- 它的核心效率机制，正好也是优化难点

6.3 lecture4 给出的三类解决路线

slide 中总结了三条主要路径：

1. reinforcement learning
2. stochastic perturbations / stochastic approximations
3. heuristic balancing losses

而且讲义故意追问一句：

> 猜猜实践里大家真正用的是哪个?

答案基本是：

- 第三类启发式方法

6.4 RL 路由：从理论上更“正宗”，但实践中不够划算

RL 思路很自然：

- 把路由看成策略
- 用 REINFORCE 或类似方法学习

但 lecture4 给出的判断很现实：

- 它能工作
- 但没有强到足以成为明确胜利方案
- 梯度方差大
- 实现和训练复杂

所以 RL 常被视为“原则上更正确”，但在工业实践里不够主流。

6.5 随机近似：给 router 一点噪声

另一类办法是：

- 对路由决策加扰动

例如：

- 高斯扰动
- uniform multiplicative jitter

这样做的直觉是：

- expert 不会变得过于脆弱
- router 会学到更稳健的排序

6.6 启发式 balancing loss：最实用但也最 heuristic

实践中最常见的方法还是：

- 额外加一些负载均衡目标

其核心目的不是直接提高语言建模能力，而是：

- 避免某些 expert 被过度使用
- 避免某些 expert 长期闲置
- 让系统吞吐更稳定

也就是说，MoE 的训练目标里通常混着两种东西：

1. 任务目标

2. 系统友好的辅助目标

这正是 lecture4 所说“training objectives are somewhat heuristic”的含义。

7. Load balancing、稳定性与训练技巧

这一节是 MoE 最工程化的一部分。

7.1 为什么 load balancing 是生死线

MoE 并不是只要能路由就行。
从系统角度看，最怕的是：

- 少数 expert 爆满
- 大量 expert 闲置

这会导致：

- 并行效率差
- 某些设备过载
- token dropping
- 路由不稳定

因此：

> MoE 不仅要“学会分工”，还要“分得均匀”。

7.2 Switch Transformer 风格 balancing loss

lecture4 给出的最经典参考是 Switch Transformer。

其核心想法是：

- 对经常被选中的 expert 施加更强下压
- 让整体使用频率更均衡

Heuristic balancing losses

Another key issue – systems efficiency requires that we use experts evenly..

For each Switch layer, this auxiliary loss is added to the total model loss during training. Given N experts indexed by $i = 1$ to N and a batch $\mathcal{B}$ with T tokens, the auxiliary loss is computed as the scaled dot-product between vectors f and P,

$$\text{loss} = \alpha \cdot N \cdot \sum_{i=1}^{N} f_i \cdot P_i \tag{4}$$

where f_i is the fraction of tokens dispatched to expert i,

$$f_i = \frac{1}{T} \sum_{x \in \mathcal{B}} \mathbb{1}\{\text{argmax}\, p(x) = i\} \tag{5}$$

and P_i is the fraction of the router probability allocated for expert i, [2]

$$P_i = \frac{1}{T} \sum_{x \in \mathcal{B}} p_i(x). \tag{6}$$

From the Switch Transformer [Fedus et al 2022]

The derivative with respect to $p_i(x)$ is $\frac{\alpha N}{T^2} \sum 1_{argmax\ p(x)=i}$,
so more frequent use = stronger downweighting

最值得记住的不是具体公式，而是优化逻辑：

- 用 auxiliary loss 把 router 往“更均匀”方向推

7.3 per-expert balancing vs per-device balancing

lecture4 还指出一个很实用的升级：

- 不只是看 expert 是否均衡
- 还要看设备级别是否均衡

因为在真实系统里，最终 bottleneck 往往不是抽象 expert，而是：

- 哪台设备收到多少 token
- 通信是否均衡
- 某个节点会不会被打爆

所以 DeepSeek 等设计里会出现：

- per-expert balancing
- per-device balancing

两类目标并存。

7.4 DeepSeek v3 的“auxiliary-loss-free” 变体

lecture4 里提到一个很有代表性的变体：

- 给每个 expert 设一个 bias
- 用在线更新方式调节这些 bias

直觉上，这相当于：

- 如果某个 expert 最近吃到的 token 太少，就提高它的偏置
- 让它更容易被选中

DeepSeek v3 variation – per-expert biases

Set up a per-expert bias (making it more likely to get tokens) and use online learning

$$g'_{i,t} = \begin{cases} s_{i,t}, & s_{i,t} + b_i \in \mathrm{Topk}(\{s_{j,t} + b_j | 1 \leqslant j \leqslant N_r\}, K_r), \\ 0, & \text{otherwise.} \end{cases}$$

They call this ‘**auxiliary loss free balancing**’

Complementary Sequence-Wise Auxiliary Loss. Although DeepSeek-V3 mainly relies on the auxiliary-loss-free strategy for load balance, to prevent extreme imbalance within any single sequence, we also employ a complementary sequence-wise balance loss:

$$\mathcal{L}_{\mathrm{Bal}} = \alpha \sum_{i=1}^{N_r} f_i P_i, \tag{17}$$

$$f_i = \frac{N_r}{K_r T} \sum_{t=1}^{T} \mathbb{1}\left(s_{i,t} \in \mathrm{Topk}(\{s_{j,t} | 1 \leqslant j \leqslant N_r\}, K_r)\right), \tag{18}$$

$$s'_{i,t} = \frac{s_{i,t}}{\sum_{j=1}^{N_r} s_{j,t}}, \tag{19}$$

$$P_i = \frac{1}{T} \sum_{t=1}^{T} s'_{i,t}, \tag{20}$$

(but the approach is not fully aux loss free..)

讲义也提醒了一个很好的工程态度：

> 它被称为“auxiliary loss free balancing”，但并不是真的完全没有 auxiliary 成分。

这说明你在看论文命名时要保持警惕：

- 名字可能强调某个方向
- 但具体实现未必完全摆脱该类思想

7.5 移除 balancing loss 会怎样

lecture4 专门放了一页问：

> 去掉 load balancing loss 会发生什么?

虽然 slide 这里更偏经验展示，但核心结论很明确：

- 不做 balancing 往往会显著恶化训练或系统效率

这是因为 MoE 最大的风险之一就是路由坍缩：

- 一些 expert 被疯狂偏好
- 一些 expert 基本不学东西

7.6 router 的数值稳定性

MoE 的另一个独特稳定性问题在 router 上。

讲义给出的经验解法是：

- router 单独使用 float32
- 有时再加一个 z-loss

Issues with MoEs - stability

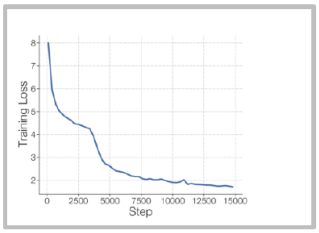

[7]Exponential functions have the property that a small input perturbation can lead to a large difference in the output. As an example, consider inputting 10 logits to a softmax function with values of 128 and one logit with a value 128.5. A roundoff error of 0.5 in `bfloat16` will alter the softmax output by 36% and incorrectly make all logits equal. The calculation goes from $\frac{\exp(0)}{\exp(0)+10\cdot\exp(-0.5)} \approx 0.142$ to $\frac{\exp(0)}{\exp(0)+10\cdot\exp(0)} \approx 0.091$. This occurs because the max is subtracted from all logits (for numerical stability) in softmax operations and the roundoff error changes the number from 128.5 to 128. This example was in `bfloat16`, but analogous situations occur in `float32` with larger logit values.

[Zoph 2022]

Solution: Use Float 32 just for the expert router (sometimes with an aux z-loss)

$$L_z(x) = \frac{1}{B}\sum_{i=1}^{B}\left(\log\sum_{j=1}^{N} e^{x_j^{(i)}}\right)^2 \tag{5}$$

这很值得注意，因为它说明：

- 即使主干模型大量使用低精度
- 某些极小但关键的组件仍值得保留更高精度

7.7 z-loss 的角色

router z-loss 的角色与 lecture3 里 softmax 稳定性讨论是一脉相承的：

- 控制 logits 尺度
- 降低数值爆炸
- 让路由 softmax 更稳

这再次体现：

- MoE 的难点并不只是架构
- 还包括“如何让 router 的数值行为足够好”

7.8 微调阶段的额外风险

lecture4 还提到：

- sparse MoE 在较小微调数据上更容易过拟合

这是一个很实际的问题，因为 MoE 的容量巨大，而微调数据往往远少于预训练数据。

一些对应策略包括：

- 只微调非 MoE MLP
- 使用更多监督数据

这意味着：

- 预训练好的 MoE，不代表下游微调就天然更轻松

8. 系统与基础设施视角下的 MoE

如果只从论文公式看 MoE，很容易误以为它只是“多了一个 router”。
但 lecture4 很强调另一件事：

> MoE 的真正难点往往在系统侧。

8.1 为什么说它“好并行”

MoE 的一大优点是：

- 每个 expert 可以放在不同设备上

从参数扩展角度看，这非常有吸引力，因为：

- 不需要每张卡都容纳全部 expert 参数
- 你可以把总容量分散到更多设备

Training MoEs – the systems side

MoE routing allows for parallelism, but also some complexities

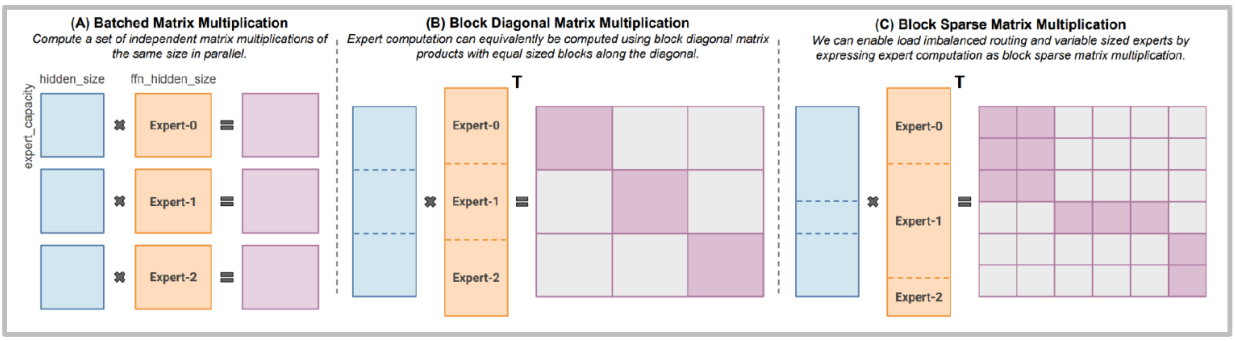

Modern libraries like MegaBlocks (used in many open MoEs) use smarter sparse MMs

8.2 为什么它又“更复杂”

并行友好并不等于实现简单。
因为一旦 token 被分发到不同 expert，就会引出很多系统问题：

- token 如何重排
- expert 间负载是否均衡
- 跨设备通信如何做
- all-to-all 代价多大
- 稀疏矩阵乘法如何高效实现

所以真正的 MoE 系统往往需要：

- 更复杂的 dispatch / combine 逻辑
- 更成熟的 sparse MM 内核
- 更精细的通信调度

8.3 为什么现代库开始变得关键

lecture4 提到如 MegaBlocks 这样的库，是因为：

- 没有高质量稀疏矩阵乘法实现
- MoE 的很多理论优势会在工程上被吃掉

这再一次说明：

- MoE 强不强，部分取决于架构
- 但很大程度也取决于系统栈有没有跟上

8.4 token dropping 与 batch-level stochasticity

lecture4 还提到一个有趣但很实际的问题：

- MoE 的随机性可能来自 batch 级路由

如果路由阶段存在：

- capacity limit
- token dropping

那么某个 token 是否真的能进入目标 expert，不只取决于它自己，也取决于同 batch 里其他 token。

这意味着：

- 其他人的请求有时会影响你的 token 是否被丢掉

这正是 “MoE stochasticity” 比 dense 模型更强的一部分来源。

8.5 为什么 MoE 的系统目标和模型目标绑得很紧

dense 模型里，系统优化和模型学习常常相对可分。
而在 MoE 里，二者会深度耦合，因为：

- 路由方式直接决定计算图
- 负载均衡直接决定吞吐
- 容量限制直接改变训练数据实际流向

所以 MoE 里很多“训练技巧”其实同时是：

- 优化技巧
- 系统技巧

9. 近期代表性设计：Switch、Mixtral、Qwen、DeepSeek、OlMoE

这一节不是做论文综述，而是把 lecture4 里的代表性模型压成几个设计趋势。

9.1 Switch Transformer：最经典的稀疏路由 baseline

Switch Transformer 的标志性设定是：

- top-1 routing
- 强调简单高效
- 配套 load balancing loss

它的重要性在于：

- 它把“简单稀疏路由也能 work”这件事做成了一个强基线

9.2 Mixtral / DBRX：更典型的现代 top-k sparse MoE

这些模型代表了一种更常见的现代做法：

- top-k routing
- active experts 小
- routed experts 不算太少

它们体现的思路是：

- 不必极端到 top-1
- 适度多 expert 激活可能在表达与稳定性间更平衡

9.3 Qwen / DeepSeek：shared experts 与 fine-grained experts 的系统探索

Qwen 与 DeepSeek 系列很有代表性，因为它们不仅在做“经典 top-k”，还在探索：

- 更细粒度的 routed experts
- 少量总是开启的 shared experts
- 更复杂的 balancing 机制

这些设计常常体现一种工程判断：

- 完全纯 sparse 路由不一定是最稳的
- 给模型留一条共享基础通路，可能更有利

9.4 OlMoE：shared experts 未必总有用

lecture4 很好的地方在于，它没有把 shared experts 神化。
OlMoE 的 ablation 给出的信息是：

- fine-grained experts 有收益
- shared experts 不一定有收益

这说明：

- shared experts 是一种合理设计
- 但并不是无条件默认最优

9.5 DeepSeek v1 -> v2 -> v3：一条非常典型的演化路线

lecture4 结尾专门用几页讲 DeepSeek v1/v2/v3，很适合当作一个案例研究。

DeepSeek v1

- shared + fine-grained experts
- 标准 top-k routing
- 标准 aux-loss balancing

DeepSeek v2

- expert 数量进一步扩大
- 引入 top-M device routing
- 加入 communication balancing

DeepSeek v3

- 更大的 routed expert 总数
- active experts 仍控制在较小范围
- sigmoid + softmax top-k + top-M
- aux-loss-free / seq-wise aux 风格的 balancing

DeepSeek MoE v1-v2-v3

To wrap up, we'll walk through the DeepSeek MoE architecture.

V1 (16B – 2.8 active):

Shared (2) + Fine-grained (64/4) experts

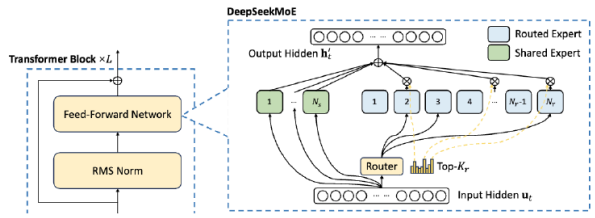

Standard, top-k routing

$$\mathbf{h}_t' = \mathbf{u}_t + \sum_{i=1}^{N_s} \mathrm{FFN}_i^{(s)}(\mathbf{u}_t) + \sum_{i=1}^{N_r} g_{i,t}\,\mathrm{FFN}_i^{(r)}(\mathbf{u}_t),$$

$$g_{i,t} = \begin{cases} s_{i,t}, & s_{i,t} \in \mathrm{Topk}(\{s_{j,t} | 1 \leqslant j \leqslant N_r\}, K_r), \\ 0, & \text{otherwise}, \end{cases}$$

$$s_{i,t} = \mathrm{Softmax}_i\left(\mathbf{u}_t{}^T \mathbf{e}_i\right),$$

Standard Aux-loss balancing (Expert + Device)

$$\mathcal{L}_{\mathrm{ExpBal}} = \alpha_1 \sum_{i=1}^{N_r} f_i P_i,$$

$$f_i = \frac{N_r}{K_r T} \sum_{t=1}^{T} \mathbb{1}(\text{Token } t \text{ selects Expert } i),$$

$$P_i = \frac{1}{T} \sum_{t=1}^{T} s_{i,t},$$

DeepSeek MoE v3

V2 (671B – 37 active):

Shared (1) + Fine-grained (258) experts, 8 active

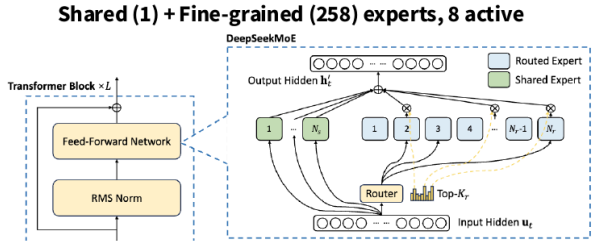

New things

Sigmoid+Softmax topK + topM

$$\mathbf{h}_t' = \mathbf{u}_t + \sum_{i=1}^{N_s} \mathrm{FFN}_i^{(s)}(\mathbf{u}_t) + \sum_{i=1}^{N_r} g_{i,t}\,\mathrm{FFN}_i^{(r)}(\mathbf{u}_t),$$

$$g_{i,t} = \frac{g'_{i,t}}{\sum_{j=1}^{N_r} g'_{j,t}},$$

$$g'_{i,t} = \begin{cases} s_{i,t}, & s_{i,t} \in \mathrm{Topk}(\{s_{j,t} | 1 \leqslant j \leqslant N_r\}, K_r), \\ 0, & \text{otherwise}, \end{cases}$$

$$s_{i,t} = \mathrm{Sigmoid}\left(\mathbf{u}_t{}^T \mathbf{e}_i\right),$$

Aux-loss-free + seq-wise aux

$$g'_{i,t} = \begin{cases} s_{i,t}, & s_{i,t} + b_i \in \mathrm{Topk}(\{s_{j,t} + b_j | 1 \leqslant j \leqslant N_r\}, K_r), \\ 0, & \text{otherwise}. \end{cases}$$

这条演化路线告诉你：

> 一个成熟的 MoE 设计，不只是“把 expert 数量加大”，而是 routing、balancing、device-level communication、shared expert 设计一起进化。

9.6 DeepSeek v3 还不只是 MoE

lecture4 还额外提到：

- MLA（Multi-head Latent Attention）
- MTP（多步预测）

这其实在提醒你：

- 强大的现实模型通常不是靠单一技巧取胜
- MoE 只是其中一个关键部件

也就是说：

- 一个成功的工业级大模型通常是“多种架构和系统优化的叠加”

10. 如果今天自己做一个 MoE，该默认怎么想

这一节把 lecture4 的经验压缩成一套“现代默认直觉”。

10.1 先回答：你为什么要用 MoE

如果你的目标是：

- 在相近 FLOPs 下扩大总参数容量
- 利用更多设备扩展模型容量
- 做更强的大模型预训练

那么 MoE 很值得考虑。

如果你的目标是：

- 快速实现
- 极简训练栈
- 小规模单机实验

那么 dense 模型往往仍是更稳妥的默认起点。

10.2 默认替换位置

若没有特别强理由，优先：

- 在 FFN/MLP 位置做 MoE

而不是先在 attention 上做 MoE。

10.3 默认 routing

若没有非常新颖的研究目标，默认从：

- token-choice top-k routing

开始。

这是目前最强的工程默认项。

10.4 默认 balancing 思路

不要幻想“不做 balancing 也行”。
一个更现实的默认配置是：

- 至少有某种 per-expert balancing
- 如系统规模较大，再加入 per-device balancing
- router 用 float32
- 必要时加 z-loss 或其他 logit 稳定措施

10.5 shared experts 要不要加

保守建议是：

- 可以把它当成值得实验的选项
- 但不要把它视为铁律

因为现有经验并不完全一致。

10.6 真正的默认心智模型

如果用一句话总结 MoE 的默认工程心智模型：

> 先把 MoE 看成“稀疏化 FFN + top-k router + balancing + 通信调度”的联合系统，而不是一个只需要加 router 的小改动。

11. 高频考点与常见误区

11.1 高频结论

- MoE 最常见的做法是替换 Transformer block 中的 FFN
- MoE 的价值来自稀疏激活，不是简单参数堆叠
- “参数量更大但 FLOPs 相近”是 MoE 的核心卖点
- 现代 MoE 几乎都使用 token-choice top-k routing
- load balancing 是 MoE 训练和系统效率的关键
- router 往往需要特殊数值稳定性处理
- MoE 的优势与系统基础设施强相关
- shared experts 是重要但并未完全定论的设计点

11.2 常见误区

误区 1：MoE 就是“更大的模型”

不对。
MoE 的核心不是“大”，而是“总容量更大，但每个 token 只走其中一部分”。

误区 2：参数不变 FLOPs 不变就说明实现也简单

不对。
系统复杂度、通信和稀疏矩阵乘法，往往才是 MoE 的真正难点。

误区 3：routing 只是一个小模块

不对。
routing 决定了：

- 哪些参数被激活
- 负载是否均衡
- 通信如何发生
- 训练是否稳定

误区 4：只要 top-k 能跑起来就行

不对。
不做 balancing，或者 router 数值不稳，MoE 很容易退化。

误区 5：MoE 一定优于 dense

不对。
它常常在大规模训练和多设备环境下更有吸引力，但并不是任何场景下都更划算。

12. 附：最小 MoE 代码骨架

这部分不给完整工业实现，只给 lecture4 最相关的核心骨架。

12.1 一个最小 router

```
import torch
from torch import nn


class TopKRouter(nn.Module):
    def __init__(self, d_model: int, num_experts: int, k: int):
        super().__init__()
        self.k = k
        self.proj = nn.Linear(d_model, num_experts, bias=False)

    def forward(self, x: torch.Tensor):
        # x: [tokens, d_model]
        scores = self.proj(x)
        topk_scores, topk_idx = torch.topk(scores, k=self.k, dim=-1)
        topk_weight = torch.softmax(topk_scores, dim=-1)
        return topk_idx, topk_weight
```

12.2 一个最小 expert

```
class ExpertFFN(nn.Module):
    def __init__(self, d_model: int, d_ff: int):
        super().__init__()
        self.w1 = nn.Linear(d_model, d_ff, bias=False)
        self.w2 = nn.Linear(d_ff, d_model, bias=False)

    def forward(self, x: torch.Tensor) -> torch.Tensor:
        return self.w2(torch.relu(self.w1(x)))
```

12.3 一个最小 MoE 前向

```
class SimpleMoE(nn.Module):
    def __init__(self, d_model: int, d_ff: int, num_experts: int, k: int):
        super().__init__()
        self.router = TopKRouter(d_model, num_experts, k)
        self.experts = nn.ModuleList(
            [ExpertFFN(d_model, d_ff) for _ in range(num_experts)]
        )

    def forward(self, x: torch.Tensor) -> torch.Tensor:
        # 教学版：不做高效 dispatch，只表达计算逻辑
        topk_idx, topk_weight = self.router(x)
        out = torch.zeros_like(x)

        for token_i in range(x.size(0)):
            token_out = 0.0
            for j in range(topk_idx.size(1)):
                e = topk_idx[token_i, j].item()
                w = topk_weight[token_i, j]
                token_out = token_out + w * self.experts[e](x[token_i:token_i+1]).squeez
            out[token_i] = token_out
        return out
```

这个版本当然不高效，但很适合理解 MoE 的前向本质：

- router 决定去哪些 expert
- expert 各自算 FFN
- 输出按 gate 权重加权回来

12.4 一个 lecture4 风格的现代默认配置

```
moe_defaults = {
    "replace_where": "FFN only",
    "routing": "token-choice top-k",
    "active_experts": "small k",
    "balancing": "per-expert + maybe per-device",
    "router_precision": "fp32",
    "shared_experts": "worth trying, not guaranteed best",
    "systems_priority": "dispatch + communication + sparse MM matter a lot",
}
```

13. 一句话总结构图

如果只用一句话概括 lecture4：

> MoE 的本质，是用稀疏路由把“更大的总参数容量”和“较低的单 token 计算量”同时装进 Transformer 里，但你必须为此付出 routing、load balancing、稳定性与系统复杂度上的额外代价。